
Ubicación de Estaciones de Carga de Autos Eléctricos mediante Algoritmos Genéticos Multiobjetivo

F.J.A. Maldonado y H. Correa
Facultad de Ingeniería y Ciencias Hídricas, Universidad Nacional del Litoral
Instituto de Investigación en Señales, Sistemas e Inteligencia Computacional, UNL-CONICET

Resumen

La creciente adopción de vehículos eléctricos (VE) exige diseñar redes de recarga eficientes y sostenibles. Este trabajo propone un marco de optimización multiobjetivo para ubicar estaciones de recarga usando un algoritmo evolutivo de ordenamiento no-dominado (NSGA-II). El problema se formula sobre un conjunto de nodos geoespaciales (representando esquinas o puntos representativos) del fichero `dataset_final.gpkg`, obtenido mediante la librería OSMNX y datasets de flujo de tráfico. Los objetivos considerados son: minimizar la cantidad de estaciones instaladas, minimizar la máxima distancia de cobertura a cualquier nodo y maximizar la prioridad de ubicación de estaciones de carga. Para abordar estos objetivos se define una representación binaria por nodo, tres funciones de fitness modulares y una configuración del algoritmo basado en pymoo, y geopandas para los datos.

Se realizaron experimentos variando parámetros clave como la distancia máxima `d_max`, penalizaciones y tamaño de población. Los resultados de los parámetros de la solución se presentan en forma de frontera de Pareto como corresponde en un algoritmo con múltiples fitness. La frontera pone en evidencia los trade-offs entre coste (nº de estaciones) y beneficio (cobertura de distancias, y prioridad de flujo y densidad geográfica). Se discuten limitaciones del enfoque y se proponen extensiones prácticas que no pudieron ser incluidas al delimitar el problema. El marco entregado está acotado y sirve como herramienta de apoyo para la planificación de infraestructura de recarga en distintos entornos, principalmente los abarcados por rutas.

1. Introducción

La transición hacia la movilidad eléctrica es una prioridad global promovida por muchos gobiernos por sus beneficios ambientales y de salud. Implementar una red de estaciones de recarga eficiente es clave para facilitar dicha transición. El desafío técnico es diseñar ubicaciones que equilibren costo, cobertura y prioridad de servicio, además de disponibilidad de espacio y energía necesaria. Los vehículos eléctricos presentan limitaciones de autonomía que hacen crucial la planificación espacial de puntos de recarga. Además, zonas rurales y rutas interurbanas agregan complejidad por las grandes distancias entre nodos y menor flujo que las zonas urbanas.

Este trabajo investiga una solución basada en algoritmos evolutivos multiobjetivo. Los Algoritmos Genéticos, y en particular NSGA-II, son adecuados para problemas con objetivos conflictivos porque entregan una aproximación de la frontera de Pareto, donde la mejora de un objetivo implica un deterioro de otro, y preservan diversidad en la población. En contraste con estudios previos, aquí se presta atención tanto a entornos urbanos como a entornos de mayor escala espacial, donde las distancias y la dispersión de la demanda donde se incluyen lugares remotos son notables.

El objetivo práctico es proveer un procedimiento reproducible y escalable para generar alternativas de diseño (soluciones no dominadas) que faciliten la toma de decisiones de planificadores y operadores a la hora de hacer una migración hacia el uso extendido de vehículos eléctricos.

De entre los trabajos revisados en cuando a ubicación óptima de estaciones, destacamos principalmente el perteneciente a los autores Xue Bai, Kwai-Sang Chin, Zhili Zhou, el cual utiliza el propio algoritmo de NSGA-II para resolver el problema de optimización de estaciones en la ciudad de Shenzhen (China), considerando como parámetros la densidad de tráfico (medida por datos en tiempo real de GPS) y la capacidad eléctrica y necesidad de inversión de los puntos posibles a colocar las mismas. Esto se encuentra relacionado con nuestra idea, diferenciando que en tal caso se realiza para una urbanización de gran densidad poblacional y se utilizan otros parámetros a optimizar debido a la diferencia de objetivos y datasets obtenidos con respecto a nuestro trabajo en particular.

La producción de Kizhakkan, A. R., Rathore, A. K., & Awasthi corresponde a una revisión sistemática y comparativa sobre los métodos, modelos y enfoques que se utilizan para planificar la ubicación óptima de estaciones de carga para vehículos eléctricos (EVCS). Allí se destacan por sobre otros métodos los de índole evolutivo, específicamente algoritmos genéticos y variantes como el NSGA-II.

Por otro lado, Albert Y.S. Lam, Yiu-Wing Leung, and Xiaowen Chu realizan en su trabajo una formulación teórica/matemática al problema de optimización de ubicación de estaciones de carga, considerando factores a tener en cuenta, complejidad y posibles soluciones al mismo. Desde esta base teórica surge nuestra idea de representar la información a utilizar en la optimización en un grafo, y fórmulas a implementar en las funciones de fitness.

2. Método

Para resolver el problema se utilizó el ya mencionado NSGA-II (No-Dominated Sorting Genetic Algorithm) de la librería pymoo, este algoritmo genético multiobjetivo permite hacer uso de una Frontera de Pareto, para problemas donde una solución con mejor fitness en un objetivo empeore necesariamente el resultado en otro.

En el mismo, se utiliza el método de selección de torneo, pero con frentes de dominancia (dominance rank): se arman frentes o grupos de soluciones en base al nivel de dominación que tienen. Una vez clasificadas, se realiza el torneo propiamente dicho, y se selecciona en primer grado la que posea mejor frente, y en segundo grado la que posea mayor distancia al resto de soluciones de su frente (crowding distance).

Utiliza para la reproducción de individuos cruza binaria uniforme y mutación polinomial, y la generación siguiente a la actual se forma reemplazando desde los individuos que forman el primer frente en adelante, hasta completar la población.

Se utiliza el algoritmo de NSGA-II correspondiente a la librería de pymoo, con sus parámetros por defecto a excepción de los mencionados posteriormente.

3. Datos y diseño experimental

3.1. Obtención de datos

Los datos se cargan desde un archivo llamado `'dataset_final.gpkg'` usando las librerías `osmnx`, `geopandas` y `pandas`. Dicho dataset, está dado para el Condado de San Joaquín, California, EE.UU.

Este dataset es la unificación de un dataset perteneciente a un grafo (de nodos correspondientes a rutas con sus coordenadas, distancias y cantidad de esquinas que rodea cada nodo) y un dataset con el flujo de tráfico para determinados puntos en vías de alta velocidad/capacidad.




figura 1: Nodos finales (488 nodos) con información de coordenadas, flujo de tráfico y cantidad de esquinas alrededor del Condado de San Joaquín, California, EE. UU. Las conexiones representadas corresponden a rutas, autopistas y similares.

El primer dataset fue obtenido mediante la librería de OSMNX (que accede a datos satelitales del sistema geográfico abierto OpenStreetMap) y, dado un determinado territorio, realiza un grafo con nodos correspondientes a intersecciones o relevantes para el sistema geográfico. A éstos se los filtra para obtener solo aquellos pertenecientes a rutas, autopistas, autovías y carriles rápidos. Finalmente, se calcula un valor para cada nodo que corresponde a la cantidad de esquinas que posee a su alrededor para un radio de 1km, que busca representar con este valor la densidad de población alrededor del mismo (suponiendo que mientras mayor cantidad de calles, mayor densidad poblacional existe).

El segundo dataset fue obtenido mediante la unificación de dos dataset diferentes del tipo .geojson. El primero contiene el flujo de tráfico diario en distintos puntos de rutas dependientes del Condado de San Joaquín, California. El segundo posee la misma información, pero para rutas que se encuentran dentro del condado de San Joaquín que dependen del propio Estado de California (fueron filtrados puntos de rutas que no se encuentren dentro del estado de San Joaquín, ya que poseía flujos de todo el estado).

La información de estos datasets fue unificada tomando como referencia 488 nodos del grafo obtenido con OSMNX, y asignando a cada uno de ellos un promedio ponderado

de los puntos con flujo más cercanos.

3.2. Implementación del algoritmo

Para este algoritmo, se representan los individuos como un numero binario de longitud igual a la cantidad de nodos, donde el valor (1 o 0) indica la presencia o ausencia de estación en dicho nodo. Asimismo, se usan tres funciones de fitness:

- f_1 : penaliza la cantidad de estaciones por individuo (normalizado por n_nodos y con factor de importancia $factor_estaciones$), además de una penalización por exceso de cantidad de estaciones sobre un valor máximo.

$$f_1(z) = \alpha \frac{\sum_i z_i}{N} + penalización$$

- f_2 : cobertura global medida como la distancia máxima desde cualquier nodo a su estación más cercana; se penalizan distancias mayores que d_max con una constante elevada (se busca evitar distancias entre estaciones mayores a d_max).

$$f_2(\mathbf{z}) = \max_{j \in N} \min_{i: z_i=1} d(j, i)$$

donde $d(j, i)$ es la distancia euclídea entre nodos j e i . En la implementación se normaliza por d_{max} .

- f_3 : prioridad invertida por nodo, inverso a la media (prioridad de estaciones). La prioridad está compuesta por el flujo total por nodo y la cantidad de esquinas en un radio, y se calcula como el promedio de la prioridad de todos los nodos.

$$P_i = w_f \frac{f_i}{f_{max} + \varepsilon} + w_s \frac{s_i}{s_{max} + \varepsilon}$$

$$f_3 = \begin{cases} \frac{1}{|E|} \sum_{i \in E} P_i, & |E| > 0 \\ 0, & |E| = 0 \end{cases}$$

La prioridad p_i se computa como combinación lineal de atributos normalizados Con pesos w_f y w_e .

Configuración y parámetros:

- ✓ **d_max** = 10,000 m (máxima distancia de cobertura para cada nodo)
- ✓ **pop_size** = 400 (Tamaño de población fija, no varía con las generaciones)
- ✓ **n_gen** = 1500 (Cantidad de generaciones)
- ✓ **factor_estaciones** = 10 (Peso asignado a la función de fitness)
- ✓ **max_ratio** = 0.5 (máximo porcentaje de nodos que pueden ser estaciones)
- ✓ **factor_estaciones** = 5.0 (factor para ponderar la cantidad de estaciones)
- ✓ **peso_flujo** = 0.7 (factor para ponderar el flujo por cada nodo)
- ✓ **peso_esquinas** = 0.3 (factor para ponderar la influencia de la densidad de nodos)
- ✓ **Gdf** (dataset de nodos en formato .gpkg (geopackage))

4. Resultados y discusión

El algoritmo produce una frontera de Pareto compuesta por soluciones de compromiso entre número de estaciones y cobertura de distancias, y densidad geográfica por esquinas y de flujo. Se observan gran variedad de soluciones para distintos valores de la frontera, donde se encuentran soluciones con pocas estaciones que sacrifican cobertura en nodos aislados, soluciones que incrementan estaciones y reducen significativamente la distancia máxima de cobertura, y soluciones donde se observa que la prioridad media permite distinguir soluciones que favorecen nodos con mayor flujo.

Soluciones obtenidas (son todas no dominadas):			
	num_estaciones	distancia_max_km	prioridad_media
0	133	3.258021	0.282715
1	135	3.258021	0.286632
2	41	25.820791	0.520027
3	48	25.820791	0.540530
4	135	3.258021	0.286632
5	41	25.820791	0.520027
6	45	20.250264	0.529097
7	45	19.004842	0.514236
8	47	15.900928	0.514314
9	46	12.902689	0.506349
10	45	15.900928	0.506893
11	132	3.693720	0.297183
12	117	3.742078	0.316496
13	118	3.742078	0.317076
14	43	20.250264	0.516656
15	47	11.706526	0.507824

figura 2: Ejemplos de soluciones no dominadas obtenidas por el algoritmo




figura 3: Frontera de Pareto comparando soluciones por cada objetivo

Las visualizaciones 3D permiten comprender la distribución de la Frontera de Pareto, y así, seleccionar soluciones preferidas según el énfasis en distintos objetivos. Se aprecia sensibilidad también de los resultados frente a la elección de `d\_max` y la penalización por excedente. En general, existe una curva de compromiso estable entre costo (número de estaciones) y beneficio (mejora de cobertura por distancia).




figura 4: Mejores soluciones no dominadas maximizando la prioridad (flujo y densidad de esquinas) para $d_{max} = 20km$

4.1. Validación de resultados

Este trabajo de optimización de estaciones, al no poseer datos reales que sean óptimos, no pueden realizarse validaciones utilizando una ejemplificación, para lo cual se deben usar métricas que validen los resultados. Dentro de las métricas posibles vistas, se encontraban algunas que medían la calidad de soluciones al problema del agente viajero, y al encontrarse relativamente relacionadas con nuestro problema (principalmente con la

manera de verificar soluciones) utilizamos esta base a la que le incluimos distancia euclídea, verificación de flujo, densidad de esquinas y número de estaciones.

A los valores obtenidos para las métricas que calculan la efectividad de estos parámetros, los unificamos en un coeficiente de eficiencia 'e' que representa que tan optima es la solución no dominada obtenida por el algoritmo de optimización NSGA-II.

El análisis de resultados incluye también soluciones que sean dominadas para realizar una comparación de índices, obteniéndose como óptimas las que se encuentran presentes en la frontera de Pareto.

Asimismo, realizamos un algoritmo que comprueba que las soluciones no dominadas finales obtenidas por el algoritmo, son efectivamente soluciones no dominadas, para demostrar que el mismo no produce fallas ni inconsistencia en sus resultados.

4.2. Limitaciones

La calidad de las soluciones depende de la representatividad y precisión del 'dataset_final.gpkg'. Errores en atributos de flujo o en ubicaciones afectan directamente la prioridad calculada. La elección de 'd_max' y del factor de penalización puede sesgar la búsqueda hacia clases específicas de soluciones.

Otro factor limitante es el uso de distancia euclídea para el cálculo de distancias entre nodos, siendo que la distancia real es aquella que corresponde al recorrido por rutas. Esto corresponde a una limitación a la hora de medir con exactitud estos parámetros. Sin embargo, este tipo de medición logra representar relativamente la distancia de recorrido en automóvil que existe allí, y es por eso que los resultados de la optimización también resultan coherentes con respecto a las distancias. Se puede entender que este factor es una limitación, porque para el cálculo de distancias se deberían usar algoritmos exhaustivos (Dijkstra por ejemplo) que conllevan un muy alto costo computacional que no es posible afrontar para este problema en nuestro caso.

Relacionado con esto, no se modelaron costes reales de instalación, capacidad eléctrica ni restricciones urbanas. Estos factores son críticos para la implementación práctica. Por otro lado, la calidad del dataset (atributos y geometrías) condiciona fuertemente la validez de las recomendaciones. Se aconseja validar y enriquecer datos con tráfico, demanda temporal y límites regulatorios. El tiempo de cómputo crece con el número de nodos y con tamaños de población o generaciones grandes. Se recomienda realizar estudios de sensibilidad y contrastar soluciones con posibilidades de implementación de otros servicios locales.

Pese a las limitaciones, el marco propuesto es flexible y admite extensiones prácticas para análisis más detallados, para modelar este problema en otro contexto u otro problema similar.

5. Conclusiones

Se desarrolló e implementó un marco basado en NSGA-II para ubicar estaciones de recarga de vehículos eléctricos sobre un conjunto de nodos geoespaciales. La formulación multiobjetivo permite explorar el conjunto de soluciones no dominadas, mostrando los compromisos entre número de estaciones, cobertura y prioridad de servicio.

Los resultados obtenidos, evidencian que es posible reducir considerablemente la distancia máxima de cobertura aumentando moderadamente el número de estaciones, o priorizar nodos de alto flujo manteniendo un coste controlado. Sin embargo, para aplicar estas soluciones en entornos reales es necesario incorporar costes económicos, restricciones urbanas y distancias basadas en la red vial y eléctrica. así como también validación usando métricas distintas a las utilizadas en las funciones de fitness.

Recomendamos usar el presente marco como herramienta de apoyo a la decisión, complementando la salida de NSGA-II con análisis de sensibilidad y validación con expertos locales.

6. Bibliografia:

Lam, A. Y. S., Leung, Y.-W., & Chu, X. Electric vehicle charging station placement: Formulation, complexity, and solutions.

Liu, Z.-f., Zhang, W., Ji, X., & Li, K. Optimal planning of charging station for electric vehicle based on particle swarm optimization.

Awasthi, A., Venkitesamy, K., Padmanaban, S., Selvamuthukumaran, R., Blaabjerg, F., & Singh, A. K. Optimal planning of electric vehicle charging station at the distribution system using hybrid optimization algorithm.

Bai, X., Chin, K.-S., & Zhou, Z. A bi-objective model for location planning of electric vehicle charging stations with GPS trajectory data.

Okabe, A., Sugihara, K., & Sacki, E. Kernel Density Estimation of Traffic Accidents in a Network Space.